

Clasificación de Hongos Comestibles y Venenosos Mediante Aprendizaje Supervisado

Rafael Aleman, Isabela Bedoya, Alejandro Gallego

Ingeniería de Sistemas

Universidad de Antioquia

Medellín/Caucasia, Colombia

Abstract—La clasificación de hongos como comestibles o venenosos es un problema relevante en salud pública debido a los riesgos asociados a una identificación incorrecta. Este trabajo propone un sistema basado en aprendizaje supervisado utilizando el dataset UCI Mushroom, que contiene características morfológicas de distintas especies. Se describen el problema, la composición del dataset y la justificación del paradigma seleccionado, además de un estado del arte que resume trabajos previos. Estudios en la literatura muestran que modelos como Random Forest alcanzan hasta 100% de exactitud.

Index Terms—clasificación binaria, aprendizaje supervisado, hongos, Random Forest

I. DESCRIPCIÓN DEL PROBLEMA

La identificación de hongos silvestres como comestibles o venenosos es crítica debido a los riesgos para la salud. Las características morfológicas pueden ser similares entre especies, lo que dificulta su clasificación incluso para personas con experiencia.

Tradicionalmente, esta tarea ha dependido de expertos que analizan características como color, forma, olor y hábitat. Sin embargo, este enfoque no es escalable y puede presentar errores en condiciones reales.

El aprendizaje automático permite identificar patrones complejos en múltiples variables y automatizar la clasificación. Esto facilita la toma de decisiones y reduce errores críticos, especialmente aquellos en los que un hongo venenoso es clasificado como comestible.

A. Dataset

El dataset UCI Mushroom contiene 8.124 muestras con 23 variables categóricas y una variable objetivo binaria (comestible/venenoso). Presenta valores faltantes en la variable *stalk-root* (30,5%).

Estas variables incluyen atributos relacionados con el sombrero, las agallas, el tallo y el hábitat del hongo, lo que permite capturar información relevante para la clasificación. La diversidad de características hace que el problema sea adecuado para técnicas de aprendizaje automático.

B. Paradigma

Se selecciona aprendizaje supervisado debido a la disponibilidad completa de etiquetas y la naturaleza binaria del problema. Este enfoque permite entrenar modelos capaces de generalizar a nuevas muestras no vistas.

TABLE I
ESTADÍSTICAS DEL DATASET

Instancias	8.124
Variables	23 + objetivo
Clases	2
Tipo	Categóricas
Faltantes	30,5%

Además, el uso de este paradigma facilita la evaluación mediante métricas como accuracy, precision, recall y F1-score, lo cual es importante en un problema donde los errores pueden tener consecuencias críticas.

TABLE II
PARADIGMAS EVALUADOS

Supervisado	Sí	Etiquetas completas
No supervisado	No	No aplica
Semi-supervisado	No	No aplica
Refuerzo	No	No aplica

II. ESTADO DEL ARTE

TABLE III
TRABAJOS RELACIONADOS

Ref	Trabajo	Técnicas	Validación	Resultado
[1]	Arslan et al. (2024)	RF, Boosting	Train/Test	Acc > 99%
[2]	Lata et al. (2026)	AutoML	CV 10-fold	Acc = 100%
[3]	Hamonangan et al. (2021)	NB, KNN	Train/Test	KNN = 100%
[4]	Chelliah et al. (2018)	LR, SVM, RF	ROC	Árbol mejor
[5]	Paudel et al. (2022)	RF, REP Tree	CV 10-fold	Acc ≈ 100%

Los estudios coinciden en el uso de aprendizaje supervisado para clasificación binaria. Los modelos basados en árboles, especialmente Random Forest, presentan el mejor desempeño, alcanzando exactitudes cercanas al 100%.

También se observa variabilidad en las metodologías de validación, incluyendo hold-out y validación cruzada. En este trabajo se empleará validación cruzada estratificada junto con múltiples métricas para una evaluación más robusta.

Adicionalmente, algunos trabajos incorporan técnicas de interpretabilidad como SHAP, permitiendo identificar las variables más relevantes en la clasificación. Esto aporta valor en aplicaciones reales donde la explicación del modelo es importante.

III. REFERENCES

REFERENCES

- [1] M. Arslan et al., "A Comparative Study of Machine Learning Methods," 2024.
- [2] S. Lata et al., "Automated mushroom classification," 2026.
- [3] R. Hamonangan et al., "Accuracy of classification," 2021.
- [4] B. Chelliah et al., "Classification of Mushrooms," 2018.
- [5] N. Paudel et al., "Mushroom Classification," 2022.