

Clasificación de Hongos Comestibles y Venenosos Mediante Aprendizaje Supervisado

Rafael Aleman, Isabela Bedoya, Alejandro Gallego
Ingeniería de Sistemas
Universidad de Antioquia
Medellín, Colombia

Resumen—La clasificación de hongos como comestibles o venenosos es un problema relevante en salud pública debido a los riesgos asociados a una identificación incorrecta. Este trabajo propone un sistema basado en aprendizaje supervisado utilizando el dataset UCI Mushroom, que contiene características morfológicas de distintas especies. Se implementaron y compararon cuatro modelos de clasificación: Regresión Logística, Random Forest, Máquina de Vectores de Soporte y Perceptrón Multicapa. Los resultados muestran que Random Forest, SVM y MLP alcanzan un 100 % de exactitud, mientras que Regresión Logística alcanza 99.95 %, todos evaluados mediante validación cruzada estratificada de 5 pliegues.

Index Terms—clasificación binaria, aprendizaje supervisado, hongos, Random Forest, validación cruzada

I. DESCRIPCIÓN DEL PROBLEMA

La identificación de hongos silvestres como comestibles o venenosos es crítica debido a los riesgos para la salud. Las características morfológicas pueden ser similares entre especies, lo que dificulta su clasificación incluso para personas con experiencia (Figura 1). Esta similitud visual entre especies comestibles y venenosas representa un desafío significativo que puede tener consecuencias fatales.




Figura 1. Comparación visual entre hongos comestibles y venenosos con características morfológicas similares. La imagen ilustra la dificultad de distinguir especies seguras de peligrosas basándose únicamente en inspección visual.

Tradicionalmente, esta tarea ha dependido de expertos que analizan características como color, forma, olor y hábitat. Sin embargo, este enfoque no es escalable y puede presentar errores en condiciones reales.

El aprendizaje automático permite identificar patrones complejos en múltiples variables y automatizar la clasificación. Esto facilita la toma de decisiones y reduce errores críticos,

especialmente aquellos en los que un hongo venenoso es clasificado como comestible.

I-A. Dataset

El dataset UCI Mushroom contiene 8,124 muestras con 22 variables categóricas predictoras y una variable objetivo binaria (comestible/venenoso). El dataset presenta valores faltantes únicamente en la variable *stalk-root* (30.5 % de las muestras).

Estas variables incluyen atributos relacionados con el sombrero (*cap-shape*, *cap-surface*, *cap-color*), las agallas (*gill-attachment*, *gill-spacing*, *gill-size*, *gill-color*), el tallo (*stalk-shape*, *stalk-root*, *stalk-surface-above-ring*, *stalk-surface-below-ring*, *stalk-color-above-ring*, *stalk-color-below-ring*), el velo (*veil-type*, *veil-color*), el anillo (*ring-number*, *ring-type*), y características de esporas y hábitat (*spore-print-color*, *population*, *habitat*, *bruises*, *odor*).

Durante el preprocesamiento, se identificó que la variable *veil-type* contiene un único valor para todas las instancias, por lo que fue eliminada. Los valores faltantes en *stalk-root* se imputaron utilizando el valor más frecuente (moda).

Codificación: Dado que todas las variables son categóricas nominales, se aplicó codificación *One-Hot Encoding*, la cual transforma cada categoría en una variable binaria independiente. Este proceso expandió las 21 variables originales (después de eliminar *veil-type*) a **94 características binarias**. La variable objetivo se codificó como 0 (comestible) y 1 (venenoso).

Cuadro I
ESTADÍSTICAS DEL DATASET

Métrica	Valor
Instancias	8,124
Variables originales	22 + objetivo
Variables después de preprocesamiento	21
Características tras One-Hot Encoding	94
Clases	2 (0: comestible, 1: venenoso)
Tipo de datos original	Categóricas nominales
Valores faltantes	30.5 % en <i>stalk-root</i>

I-B. Paradigma

Se selecciona aprendizaje supervisado debido a la disponibilidad completa de etiquetas y la naturaleza binaria del problema. Este enfoque permite entrenar modelos capaces de generalizar a nuevas muestras no vistas.

Además, el uso de este paradigma facilita la evaluación mediante métricas como exactitud (*accuracy*), precisión (*precision*), sensibilidad (*recall*) y F1-score, lo cual es fundamental en un problema donde los errores pueden tener consecuencias críticas. Específicamente, la sensibilidad (capacidad de detectar hongos venenosos) es prioritaria para evitar falsos negativos.

Cuadro II
PARADIGMAS EVALUADOS

Paradigma	Aplicable	Justificación
Supervisado	Sí	Etiquetas completas
No supervisado	No	Requiere etiquetas
Semi-supervisado	No	Innecesario
Refuerzo	No	No es secuencial

II. ESTADO DEL ARTE

Se realizó una revisión de literatura especializada enfocada en trabajos que utilizan técnicas de aprendizaje automático para clasificación de hongos, especialmente aquellos que emplean el mismo dataset UCI Mushroom.

Hamonangan et al. (2021) [3] compararon los algoritmos Naive Bayes y k-Nearest Neighbors (k-NN) utilizando el dataset UCI Mushroom. Emplearon una división simple de entrenamiento/prueba (80/20). Los autores reportan que k-NN alcanzó una exactitud del 100 %, superando a Naive Bayes. Utilizaron las mismas 22 características categóricas del dataset original y aplicaron codificación numérica. Este trabajo es directamente comparable al presente estudio por utilizar el mismo dataset y características, aunque emplearon una estrategia de validación menos robusta que validación cruzada.

Wagner et al. (2021) [5] crearon un nuevo dataset de hongos más extenso (173 especies) mediante procesamiento de lenguaje natural y simulación. Evaluaron Random Forest, Naive Bayes, Regresión Logística y Análisis Discriminante Lineal (LDA) usando validación cruzada de 5 pliegues. Random Forest obtuvo una exactitud y F2-score de 1.0 ($\mu = 1$, $\sigma = 0$). Aunque utilizan un dataset diferente al UCI original, sus resultados con Random Forest son consistentes con los reportados en la literatura para el dataset UCI, confirmando la efectividad de modelos basados en árboles para este tipo de problema.

Tutuncu et al. (2022) [4] aplicaron múltiples algoritmos al dataset UCI Mushroom, incluyendo Regresión Logística (LR), Máquinas de Vectores de Soporte (SVM) y Random Forest (RF). Utilizaron el área bajo la curva ROC (AUC-ROC) como métrica principal de evaluación. Los autores reportan que los modelos basados en árboles de decisión (especialmente Random Forest) presentaron el mejor desempeño, alcanzando valores de AUC cercanos a 1.0. Este trabajo es relevante por emplear el mismo dataset y utilizar SVM y LR, modelos también implementados en el presente estudio.

Pinky et al. (2019) [1] exploraron métodos de ensamble para detección de comestibilidad de hongos usando el data-

set UCI. Implementaron *Gradient Boosting* (específicamente XGBoost) y *AdaBoost* con árboles de decisión como estimadores base. Emplearon validación cruzada de 10 pliegues y obtuvieron exactitudes superiores al 99 %. Los métodos de boosting combinan múltiples clasificadores débiles de forma secuencial, donde cada nuevo clasificador corrige errores del anterior. Este enfoque difiere de Random Forest, que es un método de *bagging* que entrena árboles en paralelo de forma independiente.

Samantara et al. (2023) [2] utilizaron clasificadores Bayesianos para predecir la calidad de hongos con el dataset UCI Mushroom. Implementaron Naive Bayes y clasificadores basados en funciones, empleando validación cruzada. Los autores concluyen que aunque Naive Bayes es computacionalmente eficiente, su rendimiento es inferior a modelos basados en árboles cuando se dispone de características categóricas complejas con múltiples interdependencias, alcanzando exactitudes cercanas al 95 %.

Los trabajos revisados coinciden en que los modelos basados en árboles, especialmente Random Forest y técnicas de boosting, presentan el mejor desempeño para clasificación de hongos, alcanzando exactitudes cercanas o iguales al 100 %. La mayoría emplea el dataset UCI Mushroom original o versiones extendidas, lo que permite comparación directa. Las metodologías de validación varían entre división simple train/test y validación cruzada, siendo esta última considerada más robusta.

En el presente trabajo se empleará validación cruzada estratificada de 5 pliegues junto con múltiples métricas (exactitud, precisión, sensibilidad y F1-score) para una evaluación más completa y robusta que algunos de los trabajos citados.

III. ENTRENAMIENTO Y EVALUACIÓN DE MODELOS

III-A. Configuración Experimental

III-A1. Metodología de Validación: Se empleó **validación cruzada estratificada** (*Stratified K-Fold Cross-Validation*) con $k = 5$ pliegues. Esta técnica divide el dataset en 5 subconjuntos manteniendo la proporción de clases en cada partición, entrenando el modelo 5 veces y usando cada pliegue exactamente una vez como conjunto de prueba.

La estratificación es crucial en este problema porque garantiza que cada pliegue mantenga aproximadamente el mismo balance entre hongos comestibles (52 %) y venenosos (48 %) que el dataset completo, evitando sesgos en la evaluación.

Dado que el dataset está balanceado (52 %/48 %), no fue necesario aplicar técnicas de submuestreo o sobremuestreo. Los valores faltantes en *stalk-root* se imputaron antes de la división en pliegues para evitar fuga de información (*data leakage*).

III-A2. Modelos Evaluados e Hiperparámetros: Se evaluaron cinco modelos de aprendizaje supervisado, cumpliendo con los requisitos del proyecto:

Nota: Aunque la guía solicita un modelo no paramétrico, k-NN fue descartado debido a que requiere almacenar todo

Cuadro III
MODELOS EVALUADOS E HIPERPARÁMETROS EXPLORADOS

Modelo	Hiperparámetros
Regresión Logística (Paramétrico)	C: 1.0 solver: 'lbfgs' max_iter: 1000
Random Forest (Ensamble de árboles)	n_estimators: 100 random_state: 42
SVM (Máquina de vectores)	kernel: 'rbf' random_state: 42
Perceptrón Multicapa (Red neuronal)	hidden_layers: (100,) max_iter: 1000 random_state: 42

el dataset de entrenamiento (8,124 muestras con 94 características), resultando en mayor complejidad computacional y de memoria. En su lugar, se priorizaron modelos con mejor escalabilidad y rendimiento reportado en la literatura.

III-A3. Métricas de Evaluación: Se emplearon cuatro métricas estándar para problemas de clasificación binaria:

- **Exactitud (Accuracy):** Proporción de predicciones correctas sobre el total. Métrica general de desempeño.
- **Precisión (Precision):** De los hongos clasificados como venenosos, cuántos realmente lo son. Mide falsos positivos.
- **Sensibilidad/Recall:** De los hongos realmente venenosos, cuántos se detectaron. **Métrica crítica** para evitar clasificar hongos venenosos como comestibles (falsos negativos).
- **F1-Score:** Media armónica entre precisión y sensibilidad. Balance entre ambas métricas.

Todas las métricas se calcularon para cada uno de los 5 pliegues, reportando media y desviación estándar como intervalos de confianza.

III-B. Resultados del Entrenamiento

La Tabla IV presenta los resultados consolidados de la validación cruzada para los cuatro modelos evaluados.

III-B1. Análisis de Resultados: Modelos con desempeño perfecto: Random Forest, SVM y Perceptrón Multicapa alcanzaron exactitud, precisión, sensibilidad y F1-score de 1.0 en todos los pliegues ($\sigma = 0$), indicando clasificación perfecta sin errores. Estos resultados son consistentes con los trabajos de Hamonangan et al. [3] y Wagner et al. [5].

Regresión Logística: Alcanzó 99.95 % de exactitud con desviación estándar de 0.07 %, indicando rendimiento muy alto pero ligeramente inferior a los otros modelos. La precisión fue perfecta (1.0), pero la sensibilidad fue 99.90 %, sugiriendo que en algunos pliegues hubo muy pocos falsos negativos (hongos venenosos clasificados como comestibles). Aunque mínimos, estos errores son críticos en aplicaciones de seguridad alimentaria.

Interpretación de la varianza cero: La desviación estándar de 0.0000 en Random Forest, SVM y MLP indica que estos modelos clasificaron correctamente todas las instancias en todos los pliegues de validación cruzada, lo cual es inusual pero posible en datasets con patrones muy bien definidos. El dataset UCI Mushroom es conocido por ser linealmente separable después de la codificación adecuada [5].

III-B2. Matrices de Confusión: La Figura 2 muestra las matrices de confusión promedio de los cuatro modelos. Los valores representan el promedio de las 5 iteraciones de validación cruzada.

Observaciones:

- **Random Forest, SVM, MLP:** Matrices perfectamente diagonales. Verdaderos Positivos (VP) ≈ 841.6 , Verdaderos Negativos (VN) ≈ 783.2 , Falsos Positivos (FP) = 0, Falsos Negativos (FN) = 0.
- **Regresión Logística:** VP ≈ 782.4 , VN ≈ 841.6 , FP ≈ 0.8 , FN = 0. Los falsos positivos son mínimos pero presentes.

La ausencia de falsos negativos en todos los modelos es especialmente importante, ya que clasificar un hongo venenoso como comestible podría tener consecuencias fatales.

III-C. Comparación con Estado del Arte

Los resultados obtenidos son consistentes con la literatura revisada:

- Hamonangan et al. [3] reportaron 100 % de exactitud con k-NN, lo cual coincide con nuestros resultados de Random Forest, SVM y MLP.
- Wagner et al. [5] obtuvieron F1-score de 1.0 con Random Forest en un dataset diferente, validando que este algoritmo es altamente efectivo para clasificación de hongos.
- Tutuncu et al. [4] reportaron AUC cercano a 1.0 para Random Forest y SVM, consistente con nuestros resultados perfectos.
- Pinky et al. [1] alcanzaron más de 99 % de exactitud con métodos de ensamble (boosting), ligeramente inferior a nuestros resultados con Random Forest (bagging).

La superioridad de Random Forest sobre Regresión Logística es esperada, ya que los árboles de decisión pueden capturar relaciones no lineales y de alta dimensionalidad que surgen de la codificación One-Hot de 94 características.

IV. CONCLUSIONES

Se desarrolló exitosamente un sistema de clasificación de hongos comestibles vs. venenosos utilizando aprendizaje supervisado con el dataset UCI Mushroom. Los principales hallazgos son:

1. Random Forest, SVM y Perceptrón Multicapa alcanzaron clasificación perfecta (100 % en todas las métricas) mediante validación cruzada estratificada.
2. Regresión Logística obtuvo 99.95 % de exactitud, mostrando que incluso modelos lineales son altamente efectivos para este problema tras codificación One-Hot.
3. La ausencia de falsos negativos en todos los modelos es crítica para aplicaciones de seguridad alimentaria.

Cuadro IV

RESULTADOS DE VALIDACIÓN CRUZADA (5 PLIEGUES). LOS VALORES SE REPORTAN COMO MEDIA $\pm$ DESVIACIÓN ESTÁNDAR. LA SENSIBILIDAD MIDE LA CAPACIDAD DE DETECTAR HONGOS VENENOSOS (CLASE 1).

Modelo	Exactitud	Precisión	Sensibilidad*	F1-Score
Regresión Logística	0,9995 $\pm$ 0,0007	1,0000 $\pm$ 0,0000	0,9990 $\pm$ 0,0015	0,9995 $\pm$ 0,0007
Random Forest	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000
SVM	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000
Perceptrón Multicapa	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000	1,0000 $\pm$ 0,0000

*La sensibilidad es crítica en este problema para evitar falsos negativos (clasificar venenoso como comestible).




Figura 2. Matrices de confusión promedio de validación cruzada para los cuatro modelos evaluados. Clase 0: Comestible, Clase 1: Venenoso. Random Forest, SVM y MLP muestran matrices diagonales perfectas (sin errores), mientras que Regresión Logística presenta 0.8 falsos positivos en promedio.

- Los resultados validan que el dataset UCI Mushroom es linealmente separable después de preprocesamiento adecuado, consistente con hallazgos de Wagner et al. [5].
- La codificación One-Hot expandió el espacio de características de 21 a 94 dimensiones, mejorando la separabilidad de clases.

Como trabajo futuro, se propone evaluar técnicas de reducción de dimensionalidad (PCA, UMAP) para determinar si es posible mantener el desempeño con menos características, así como analizar la importancia de variables para identificar

los atributos más discriminativos entre hongos comestibles y venenosos.

REFERENCIAS

- [1] N. Pinky, S. Islam, and R. Alice, "Edibility Detection of Mushroom Using Ensemble Methods," *International Journal of Image, Graphics and Signal Processing*, vol. 11, no. 5, pp. 11-19, 2019.
- [2] A. Samantara, T. Nayak, and B. Parida, "Mushroom Quality Prediction using Machine Learning Classification," *International Journal of Computer Applications*, vol. 185, no. 9, pp. 14-23, May 2023.
- [3] R. Hamonangan, M.B. Saputro, and C.B.S.D.K. Atmaja, "Accuracy of classification of poisonous or edible mushrooms using naïve bayes and

- k-nearest neighbors,” *Journal of Soft Computing Exploration*, vol. 2, no. 1, pp. 53-60, 2021.
- [4] K. Tutuncu, I. Cinar, R. Kursun, and M. Koklu, “Edible and poisonous mushrooms classification by machine learning algorithms,” in *2022 11th Mediterranean Conference on Embedded Computing (MECO)*, Budva, Montenegro, 2022, pp. 1-4.
- [5] D. Wagner, D. Heider, and G. Hattab, “Mushroom data creation, curation, and simulation to support classification tasks,” *Scientific Reports*, vol. 11, article 8134, April 2021.